

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«КАЗАНСКИЙ (ПРИВОЛЖСКИЙ) ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»
Институт Вычислительной математики и информационных технологий

Отчет
учебной практики (научно-исследовательская работа (получение первичных
навыков научно-исследовательской работы))

Обучающийся Филадельфов Тихон Георгиевич гр.09-535 _____
(ФИО студента) (Группа) (Подпись)

Руководитель практики от КФУ:

Доцент кафедры САИТ Андрианова А.А.

Оценка за практику _____
(Подпись)

Дата сдачи отчета « ____ » _____ 2026 г.

Казань – 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1. Классические нейронные сети и их обучение.....	4
2. Квантовая и гибридная модели в PennyLane.....	6
3. Программная реализация и методика экспериментов.....	7
4. Результаты экспериментов.....	9
4.1 Архитектура перцептрона.....	9
4.2 Скорость обучения и функция активации.....	9
4.3 Переобучение и регуляризация.....	10
4.4 Сравнение с квантовой и гибридной моделями PennyLane.....	11
ЗАКЛЮЧЕНИЕ.....	13
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	15
ПРИЛОЖЕНИЕ 1.....	17
ПРИЛОЖЕНИЕ 2.....	18

ВВЕДЕНИЕ

Учебная практика (научно-исследовательская работа (получение первичных навыков научно-исследовательской работы)) проходила на кафедре системного анализа и информационных технологий Института вычислительной математики и информационных технологий КФУ с 09 февраля 2026 по 06 июня 2026 года.

Тема работы связана с разработкой библиотеки для работы с квантовыми гибридными нейронными сетями. В первом семестре был выполнен анализ предметной области и существующих программных инструментов. Во втором семестре работа перешла в практическую плоскость. Основное внимание было уделено классическим нейронным сетям — они служат точкой отсчёта для любого сравнения, — а также практической проверке квантовой и гибридной моделей, построенных средствами библиотеки PennyLane [1].

Цель работы — исследовать классические нейросетевые модели классификации и сравнить их с квантовой и гибридной моделями PennyLane. Для достижения цели решались следующие задачи: изучить устройство и методы обучения многослойного перцептрона; исследовать влияние архитектуры, скорости обучения и функции активации на качество классификации; исследовать переобучение и способы регуляризации; изучить принципы построения гибридных моделей в PennyLane; реализовать программу для обучения и сравнения моделей и провести эксперименты на пяти наборах данных с многократными запусками.

1. Классические нейронные сети и их обучение

Многослойный перцептрон (MLP) — последовательность полносвязных слоёв [2, 3]. Каждый слой преобразует входной вектор x в выходной вектор h по формуле

$$h = f(Wx + b), \quad (1)$$

где W — матрица весов; b — вектор смещений; f — нелинейная функция активации, применяемая поэлементно.

Без нелинейности несколько слоёв сводились бы к одному линейному преобразованию. В работе рассматриваются функция ReLU $f(z) = \max(0, z)$, стандартная для скрытых слоёв, и гиперболический тангенс $\tanh z$, значения которого лежат в интервале $(-1; 1)$.

Последний слой выдаёт по одному числу z_k на каждый из K классов. Функция softmax переводит их в вероятности классов, а функцией потерь служит перекрёстная энтропия:

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad (2)$$

$$L = -\ln p_y, \quad (3)$$

где p_k — вероятность k -го класса; y — истинный класс объекта.

Обучение — минимизация средних потерь по обучающей выборке градиентным методом: на каждом шаге параметры модели θ сдвигаются в направлении антиградиента

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L, \quad (4)$$

где η — скорость обучения.

Градиенты по всем параметрам вычисляются методом обратного распространения ошибки, то есть последовательным применением правила дифференцирования сложной функции от выхода сети к входу [2, 3]. В PyTorch это выполняет механизм автоматического дифференцирования autograd [4]. Для обновления параметров используется оптимизатор Adam [5]:

он хранит скользящие средние градиента и его квадрата и за счёт этого подбирает величину шага отдельно для каждого параметра. Один проход по обучающей выборке называется эпохой.

Главная опасность при обучении — переобучение: модель с большим числом параметров запоминает обучающие примеры, включая шум, и хуже работает на новых данных [3, 6]. Признак переобучения — разрыв между точностью на обучающей и на тестовой выборке. Поэтому выборка делится на три части: обучающую, валидационную и тестовую. Параметры подбираются на обучающей части, валидационная используется для контроля обучения, а тестовая — только для итоговой оценки. Признаки предварительно стандартизуются, причём среднее и дисперсия вычисляются только по обучающей части [7].

В работе рассматриваются два способа регуляризации. Ранняя остановка прекращает обучение, если потери на валидационной выборке не уменьшаются заданное число эпох подряд, и восстанавливает веса с наилучшей валидацией [8]. L2-регуляризация (weight decay) добавляет к функции потерь штраф, который удерживает веса вблизи нуля и делает функцию, реализуемую сетью, более гладкой [9]:

$$L_{\lambda} = L + \lambda \|\theta\|^2, \quad (5)$$

где λ — коэффициент регуляризации.

Качество классификации оценивается четырьмя метриками [7, 10]. Ассигасу — доля верных ответов. Precision класса — доля верных среди объектов, отнесённых моделью к этому классу, recall — доля найденных объектов класса, F1-score — их гармоническое среднее. Для многоклассовых задач precision, recall и F1 усредняются по классам с равными весами (маско-усреднение). Влияние параметров сети и обучения на эти метрики [6, 11] исследуется в разделе 4.

2. Квантовая и гибридная модели в PennyLane

Состояние кубита описывается двумя комплексными амплитудами α и β [12, 13]:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, |\alpha|^2 + |\beta|^2 = 1. \quad (6)$$

При измерении кубит даёт 0 с вероятностью $|\alpha|^2$ и 1 с вероятностью $|\beta|^2$. Выходом квантовой схемы служит среднее значение наблюдаемой Z для каждого кубита:

$$\langle Z \rangle = P(0) - P(1). \quad (7)$$

Схема состоит из вращений кубитов на заданные углы и вентилях CNOT, связывающих кубиты между собой. Если часть углов задаётся входными данными, а часть обучается, схема становится обучаемой функцией [14]. Современные квантовые устройства невелики и зашумлены [15], а моделирование схем на обычном компьютере экспоненциально дорожает с ростом числа кубитов.

В PennyLane [1] используются стандартные шаблоны: AngleEmbedding кодирует признаки в углы вращений, по одному на кубит; StronglyEntanglingLayers — обучаемый слой вращений и вентилях CNOT; обёртка qml.qnn.TorchLayer превращает схему в модуль PyTorch. На их основе построены две модели с четырьмя кубитами и двумя слоями. Квантовая сеть (Quantum QNN) подаёт признаки в схему напрямую, а четыре значения $\langle Z \rangle$ линейно отображает в классы. Гибридная модель (Hybrid QNN, рисунок 1) содержит классический энкодер — линейный слой и функцию $(\pi/2) \cdot \tanh$, переводящие признаки в четыре угла, — ту же схему и выходной слой [16].




Рисунок 1 – Гибридная модель Hybrid QNN

3. Программная реализация и методика экспериментов

Программа написана на Python с использованием PyTorch [4], PennyLane [1] и Scikit-Learn [17]. Этапы работы вынесены в отдельные модули (таблица 1), общая схема показана на рисунке 2. Все модели обучаются одной и той же процедурой, поэтому различия в результатах связаны с моделью, а не с условиями запуска.

Таблица 1 – Модули программы

Модуль	Назначение
data.py	Загрузка наборов данных, стратифицированное разбиение, стандартизация, PCA
training.py	Обучение с ранней остановкой и регуляризацией, расчёт accuracy, precision, recall, F1-score
sem2_experiments.py	Модели MLP, Quantum QNN и Hybrid QNN, серии экспериментов, параллельный запуск, сохранение результатов
sem2_analysis.py	Сводные таблицы, критерий Уилкоксона, построение графиков




Рисунок 2 – Схема экспериментального пайплайна

Эксперименты проводились на пяти табличных наборах данных. Iris (150 объектов, 4 признака, 3 класса), Wine (178 объектов, 13 признаков, 3 класса) и Breast Cancer (569 объектов, 30 признаков, 2 класса) встроены в Scikit-Learn [17]; Moons и Circles (по 400 объектов, 2 признака, 2 класса) — синтетические двумерные задачи, для которых нужна нелинейная граница между классами.

Данные делились стратифицированно на обучающую, валидационную и тестовую выборки в пропорции 60/20/20. Для Quantum QNN признаки Wine и

Breast Cancer сжимались методом главных компонент до четырёх. Обучение: Adam со скоростью 0,01, пакет 32 объекта, до 300 эпох с ранней остановкой после 30 эпох без улучшения валидационных потерь, если в серии не указано иное. Всего проведено четыре серии экспериментов (таблица 2).

Таблица 2 – Серии экспериментов

Серия	Что варьируется	Запусков
Архитектура MLP	6 конфигураций скрытых слоёв $\times$ 5 наборов	300
Параметры обучения	скорость обучения 0,001 / 0,01 / 0,1 $\times$ ReLU и tanh $\times$ 5 наборов	300
Регуляризация	ранняя остановка $\times$ weight decay 0 / 0,001 / 0,01 $\times$ 5 наборов	300
Сравнение с PennyLane	MLP 32–16, MLP равного размера, Hybrid QNN, Quantum QNN $\times$ 5 наборов	200

Первый вариант эксперимента, выполненный в середине семестра, содержал по одному запуску каждой модели с фиксированным числом эпох, и его результаты оказались неустойчивыми: смена случайного разбиения меняла порядок моделей. Поэтому каждая конфигурация запускалась с десятью значениями seed (0–9), который задаёт и разбиение данных, и начальные веса, а модели сравнивались на одинаковых seed парным критерием Уилкоксона на уровне значимости 0,05 [18]. Запуски выполнялись параллельно в 11 процессах на ноутбуке с процессором Intel Core i7-9750H.

4. Результаты экспериментов

4.1 Архитектура перцептрона

В первой серии исследовалось влияние архитектуры перцептрона: от одного скрытого слоя из 8 нейронов (266 параметров на Breast Cancer) до трёх слоёв 64–32–16 (4626 параметров). Результаты приведены в таблице 3.

Таблица 3 – Ассигуру перцептрона при разной архитектуре (среднее по 10 запускам)

Скрытые слои	Парам. (BC)	Iris	Wine	Breast Cancer	Moons	Circles	Среднее
8	266	0,960	0,969	0,977	0,931	0,993	0,966
32	1058	0,963	0,983	0,979	0,936	0,995	0,971
128	4226	0,953	0,986	0,975	0,931	0,996	0,969
32–16	1554	0,957	0,981	0,976	0,930	0,995	0,968
64–32	4130	0,943	0,986	0,977	0,936	0,994	0,967
64–32–16	4626	0,953	0,981	0,976	0,938	0,995	0,969

Различия между архитектурами малы: средняя по наборам ассигуру лежит в пределах 0,966–0,971, что сопоставимо с разбросом между запусками. Заметно уступает только самая маленькая сеть на наборе Wine (0,969 против 0,981–0,986 у остальных): восьми нейронов недостаточно для 13 признаков и трёх классов. Увеличение сети сверх 32 нейронов не повышает качество, но ускоряет сходимость: ранняя остановка срабатывает в среднем через 160 эпох у сети из 8 нейронов и через 60 эпох у сети 64–32–16. Для небольших табличных наборов достаточно перцептрона с одним-двумя скрытыми слоями, а дальнейший рост числа параметров не окупается.

4.2 Скорость обучения и функция активации

Во второй серии для перцептрона 32–16 менялись скорость обучения (0,001, 0,01 и 0,1) и функция активации (таблица 4). Малый шаг 0,001 даёт наибольшую среднюю точность (0,971 для ReLU), но требует примерно в 2,4

раза больше эпох, чем шаг 0,01 (194 против 80). Большой шаг 0,1 ускоряет остановку (56 эпох), но снижает качество, заметнее всего на Wine (0,967 против 0,986): обучение становится менее устойчивым. Функция активации на результат почти не влияет — различия ReLU и tanh не превышают одного процентного пункта. В остальных сериях использовались ReLU и шаг 0,01 как компромисс между качеством и временем обучения.

Таблица 4 – Ассигасу перцептрона 32–16 при разной скорости обучения и функции активации

Активация, шаг	Iris	Wine	Breast Cancer	Moons	Circles	Среднее	Эпох
ReLU, 0,001	0,960	0,986	0,977	0,938	0,996	0,971	194
ReLU, 0,01	0,957	0,981	0,976	0,930	0,995	0,968	80
ReLU, 0,1	0,960	0,967	0,975	0,930	0,990	0,964	56
tanh, 0,001	0,957	0,978	0,980	0,921	0,996	0,966	207
tanh, 0,01	0,957	0,978	0,981	0,929	0,995	0,968	93
tanh, 0,1	0,953	0,972	0,974	0,926	0,991	0,963	57

4.3 Переобучение и регуляризация

В третьей серии исследовалось переобучение самой крупной сети 64–32–16. Она обучалась 300 эпох без ранней остановки и с ней, с разной силой L2-регуляризации (таблица 5). Для каждого варианта измерялась точность на обучающей и на тестовой выборке; их разность показывает степень переобучения.

Без регуляризации сеть почти полностью запоминает обучающую выборку: точность на ней 0,996, а на тесте 0,966, разрыв 3,0 п. п. Ранняя остановка сокращает разрыв почти вдвое, до 1,6 п. п., немного повышает точность на тесте (0,969) и сокращает обучение в 5 раз: в среднем 60 эпох вместо 300. Сильнее всего она помогает на зашумлённом наборе Moons (0,938 против 0,924). Weight decay 0,01 уменьшает разрыв до 1,9 п. п. без ранней остановки и до 1,2 п. п. вместе с ней, тогда как значение 0,001 практически не

действует. Точность на тесте при этом меняется мало: на небольших табличных наборах переобучение заметно по обучающей выборке, но слабо сказывается на качестве. Ранняя остановка оказалась самым полезным способом регуляризации — она одновременно защищает от переобучения и экономит время.

Таблица 5 – Переобучение перцептрона 64–32–16 (среднее по 5 наборам и 10 запускам)

Ранняя остановка	Weight decay	Ассигасу (обуч.)	Ассигасу (тест)	Разрыв, п. п.	Эпох
нет	0	0,996	0,966	3,0	300
нет	0,001	0,993	0,963	3,0	300
нет	0,01	0,985	0,966	1,9	300
да	0	0,985	0,969	1,6	60
да	0,001	0,985	0,967	1,8	53
да	0,01	0,981	0,969	1,2	60

4.4 Сравнение с квантовой и гибридной моделями PennyLane

В четвёртой серии перцептроны сравнивались с моделями PennyLane (таблица 6, рисунок 3). Кроме перцептрона 32–16 в сравнение включён перцептрон равного размера — с одним скрытым слоем, ширина которого подобрана так, чтобы число параметров совпадало с гибридной моделью (например, 59 параметров на Iris). Это позволяет отделить влияние архитектуры от влияния размера модели. F1-score во всех случаях отличается от ассигасу не более чем на 0,01, поэтому в таблице приведена только ассигасу.

Таблица 6 – Аксурасу моделей (среднее по 10 запускам) и среднее время эпохи

Модель	Iris	Wine	Breast Cancer	Moons	Circles	Эпоха, мс
MLP 32–16	0,957	0,981	0,976	0,930	0,995	18,6
MLP равн. размера	0,967	0,975	0,976	0,934	0,994	12,6
Hybrid QNN	0,970	0,967	0,982	0,905	0,993	386,1
Quantum QNN	0,927	0,897	0,895	0,896	0,995	339,5




Рисунок 3 – Аксурасу классических моделей и моделей PennyLane (среднее $\pm$ стандартное отклонение)

Гибридная модель показала качество на уровне перцептронов: на Iris и Breast Cancer немного выше (0,970 и 0,982 против 0,957 и 0,976 у перцептрона 32–16), на Wine и Moons немного ниже (0,967 и 0,905 против 0,981 и 0,930). Ни одно из этих различий не является статистически значимым (по критерию Уилкоксона p от 0,062 до 0,75). Квантовая модель без энкодера значительно уступает гибридной на Iris, Wine и Breast Cancer — на 4,3–8,7 п. п. ($p=0,002$ для Breast Cancer): признаки подаются в углы напрямую, а для Wine и Breast Cancer ещё и сжимаются до четырёх, и часть информации теряется. На двумерных Moons и Circles квантовая модель работает на уровне гибридной.

Цена квантовой части — время: эпоха гибридной модели примерно в 21 раз дольше, чем у перцептрона, а полное обучение — в 25–50 раз дольше, так как квантовая схема моделируется на классическом компьютере.

ЗАКЛЮЧЕНИЕ

В ходе учебной практики была продолжена работа над темой, связанной с разработкой библиотеки для работы с квантовыми гибридными нейронными сетями. Во втором семестре была выполнена практическая часть: изучены классические нейросетевые модели, реализована программа для обучения и сравнения моделей и проведено 1100 обучений на пяти наборах данных, каждая конфигурация запускалась десять раз.

Исследование перцептрона показало, что на небольших табличных наборах качество слабо зависит от архитектуры (средняя ассигасу 0,966–0,971); заметнее влияет скорость обучения, а шаг 0,1 делает обучение неустойчивым. Крупная сеть без регуляризации запоминает обучающую выборку (разрыв 3,0 п. п.); ранняя остановка сокращает разрыв до 1,6 п. п. и в 5 раз уменьшает число эпох, weight decay 0,01 дополнительно уменьшает разрыв.

Гибридная модель PennyLane показала качество на уровне перцептронов без статистически значимых различий, квантовая модель без энкодера уступила гибридной на 4,3–8,7 п. п. на наборах Iris, Wine и Breast Cancer. Обучение гибридной модели в десятки раз медленнее, чем перцептрона. Для систематического исследования, требующего тысяч обучений, такой скорости недостаточно — это определяет задачу следующего этапа магистерской работы: разработку собственной библиотеки с быстрым симулятором квантовых схем.

За время практики были реализованы следующие компетенции (таблица 7):

Таблица 7 – Перечень компетенций

Шифр компетенции	Расшифровка приобретаемой компетенции	Расшифровка освоения компетенции
УК-1	Способен осуществлять критический анализ проблемных ситуаций на основе системного подхода, вырабатывать стратегию действий	Проведён анализ классических нейросетевых моделей и инструментов квантового машинного обучения; выработана методика многократных запусков со статистической проверкой.
УК-4	Способен применять современные коммуникативные технологии, в том числе на иностранном(ых) языке(ах), для академического и профессионального взаимодействия	Изучены англоязычные статьи и документация PyTorch, PennyLane и Scikit-Learn; результаты оформлены в виде отчёта и статьи.
УК-6	Способен определять и реализовывать приоритеты собственной деятельности и способы ее совершенствования на основе самооценки	Спланированы этапы работы и определены задачи следующего этапа магистерской работы.
ОПК-1	Способен находить, формулировать и решать актуальные проблемы прикладной математики, фундаментальной информатики и информационных технологий	Сформулирована задача сравнения классических, квантовых и гибридных моделей классификации; определены критерии сравнения — качество классификации и время обучения.
ОПК-2	Способен применять компьютерные/суперкомпьютерные методы, современное программное обеспечение (в том числе отечественного производства) для решения задач профессиональной деятельности	Разработана программа на Python с использованием PyTorch, PennyLane и Scikit-Learn; эксперименты выполнены параллельно в нескольких процессах.
ОПК-3	Способен проводить анализ математических моделей, создавать инновационные методы решения прикладных задач профессиональной деятельности в области информатики и математического моделирования	Исследовано влияние архитектуры, параметров обучения и регуляризации на качество перцептрона; выполнено сравнение с квантовой и гибридной моделями на пяти наборах данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1) Bergholm, V. PennyLane: Automatic differentiation of hybrid quantum-classical computations [Электронный ресурс] / V. Bergholm [et al.]. — URL: <https://arxiv.org/abs/1811.04968> (дата обращения: 28.09.2026).
- 2) Хайкин, С. Нейронные сети: полный курс / С. Хайкин ; пер. с англ. — 2-е изд. — Москва : Вильямс, 2006. — 1104 с.
- 3) Гудфеллоу, Я. Глубокое обучение / Я. Гудфеллоу, И. Бенджио, А. Курвилль ; пер. с англ. — Москва : ДМК Пресс, 2018. — 652 с.
- 4) Paszke, A. PyTorch: An imperative style, high-performance deep learning library / A. Paszke [et al.] // Advances in Neural Information Processing Systems. — 2019. — Vol. 32.
- 5) Kingma, D. P. Adam: A method for stochastic optimization / D. P. Kingma, J. Ba // 3rd International Conference on Learning Representations (ICLR). — 2015. — URL: <https://arxiv.org/abs/1412.6980> (дата обращения: 28.09.2026).
- 6) Николенко, С. Глубокое обучение. Погружение в мир нейронных сетей / С. Николенко, А. Кадури, Е. Архангельская. — Санкт-Петербург : Питер, 2018. — 480 с.
- 7) Жерон, О. Прикладное машинное обучение с помощью Scikit-Learn и TensorFlow / О. Жерон ; пер. с англ. — Санкт-Петербург : Альфа-книга, 2018. — 688 с.
- 8) Prechelt, L. Early stopping — but when? / L. Prechelt // Neural Networks: Tricks of the Trade. — Berlin : Springer, 1998. — P. 55–69.
- 9) Krogh, A. A simple weight decay can improve generalization / A. Krogh, J. A. Hertz // Advances in Neural Information Processing Systems. — 1992. — Vol. 4. — P. 950–957.
- 10) Рашка, С. Python и машинное обучение / С. Рашка ; пер. с англ. — Москва : ДМК Пресс, 2017. — 418 с.
- 11) Шолле, Ф. Глубокое обучение на Python / Ф. Шолле ; пер. с англ. — Санкт-Петербург : Питер, 2018. — 400 с.

- 12) Нильсен, М. А. Квантовые вычисления и квантовая информация / М. А. Нильсен, И. Л. Чанг ; пер. с англ. — Москва : Мир, 2006. — 824 с.
- 13) Прескилл, Дж. Квантовая информация и квантовые вычисления. Т. 1 / Дж. Прескилл ; пер. с англ. — Москва ; Ижевск : НИЦ «Регулярная и хаотическая динамика», 2008. — 464 с.
- 14) Schuld, M. Circuit-centric quantum classifiers / M. Schuld, A. Bocharov, K. M. Svore, N. Wiebe // Physical Review A. — 2020. — Vol. 101. — Art. 032308.
- 15) Preskill, J. Quantum computing in the NISQ era and beyond / J. Preskill // Quantum. — 2018. — Vol. 2. — Art. 79.
- 16) Mari, A. Transfer learning in hybrid classical-quantum neural networks / A. Mari, T. R. Bromley, J. Izaac [et al.] // Quantum. — 2020. — Vol. 4. — Art. 340.
- 17) Pedregosa, F. Scikit-learn: Machine learning in Python / F. Pedregosa [et al.] // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830.
- 18) Кобзарь, А. И. Прикладная математическая статистика. Для инженеров и научных работников / А. И. Кобзарь. — Москва : Физматлит, 2006. — 816 с.

ПРИЛОЖЕНИЕ 1

СРАВНИТЕЛЬНЫЙ АНАЛИЗ КЛАССИЧЕСКИХ, КВАНТОВЫХ И ГИБРИДНЫХ НЕЙРОННЫХ СЕТЕЙ

Филадельфов Т. Г.

*Научный руководитель – канд. физ.-мат. наук, доцент, заведующий кафедрой САИТ
Васильев А. В.*

*Казанский (Приволжский) федеральный университет,
Институт вычислительной математики и информационных технологий
ipod050505@gmail.com*

Искусственные нейронные сети являются основным инструментом решения задач классификации. Одним из новых направлений развития являются гибридные квантово-классические нейронные сети, в которых часть вычислений выполняет параметризованная квантовая схема. При этом остаётся открытым вопрос, дают ли такие модели выигрыш по сравнению с классическими сетями того же размера и какой ценой он достигается.

В работе сравнивались многослойный перцептрон, перцептрон с тем же числом параметров, что у гибридной модели, а также квантовая и гибридная нейронные сети, построенные средствами библиотеки PennyLane: признаки кодируются в углы вращений четырёх кубитов, далее следуют два вариационных слоя и линейный выходной слой; у гибридной модели перед квантовой схемой добавлен обучаемый классический энкодер. Эксперименты проводились на наборах Iris, Wine, Breast Cancer, Moons и Circles, каждая модель запускалась с десятью значениями seed, различия проверялись парным критерием Уилкоксона.

Исследование перцептрона показало, что на небольших табличных наборах его качество слабо зависит от архитектуры: средняя ассигасу составляет 0,966–0,971. Крупная сеть без регуляризации запоминает обучающую выборку, а ранняя остановка сокращает разрыв между точностью на обучающей и тестовой выборках с 3,0 до 1,6 п. п. и в 5 раз уменьшает число эпох обучения.

Гибридная модель показала качество на уровне перцептронов без статистически значимых различий: например, на Breast Cancer 0,982 против 0,976, на Wine 0,967 против 0,981. Квантовая модель без энкодера уступила гибридной на 4,3–8,7 п. п. на наборах с четырьмя и более признаками. Обучение моделей PennyLane оказалось в 25–50 раз медленнее, чем перцептрона.

Таким образом, на рассмотренных задачах гибридная модель не превосходит классический перцептрон того же размера, но существенно дороже в обучении. Для систематического исследования гибридных моделей необходим более быстрый инструмент моделирования квантовых схем, разработка которого является следующим этапом работы.

ПРИЛОЖЕНИЕ 2

Модели, использованные в экспериментах (файл sem2_experiments.py):

```
def mlp(in_dim, n_classes, hidden, act="relu"):
    from torch import nn
    A = {"relu": nn.ReLU, "tanh": nn.Tanh}[act]
    layers, d = [], in_dim
    for h in hidden:
        layers += [nn.Linear(d, h), A()]
        d = h
    layers.append(nn.Linear(d, n_classes))
    return nn.Sequential(*layers)

def pl_layer(n_qubits=4, n_layers=2, diff_method="backprop"):
    import pennylane as qml
    dev = qml.device("default.qubit", wires=n_qubits)

    @qml.qnode(dev, interface="torch", diff_method=diff_method)
    def circuit(inputs, weights):
        qml.AngleEmbedding(inputs, wires=range(n_qubits), rotation="Y")
        qml.StronglyEntanglingLayers(weights, wires=range(n_qubits))
        return [qml.expval(qml.PauliZ(q)) for q in range(n_qubits)]

    return qml.qnn.TorchLayer(circuit, {"weights": (n_layers, n_qubits, 3)})

def pl_hybrid(in_dim, n_classes, n_qubits=4, n_layers=2):
    import torch
    from torch import nn

    class Angles(nn.Module): #  $(\pi/2) \cdot \tanh$ : углы кодирования в  $(-\pi/2, \pi/2)$ 
        def forward(self, x):
            return 0.5 * math.pi * torch.tanh(x)

    return nn.Sequential(nn.Linear(in_dim, n_qubits), Angles(),
        pl_layer(n_qubits, n_layers),
        nn.Linear(n_qubits, n_classes))
```